

โมดูล 4: การประมวลผล – การขยายขนาดและการแปลงชื่อ (Computing: Scaling and Name Resolution)

แปลและเรียบเรียงจากไฟล์ต้นฉบับ ACO-04-Computing-Scaling-and-Name-Resolution.pdf · ครบทั้ง 76 หน้า

หน้า 1 / 76

โมดูล 4: การประมวลผล (การขยายขนาดและการแปลงชื่อ) – Computing (Scaling and Name Resolution)

หน้า 2 / 76

วัตถุประสงค์ของโมดูล

เมื่อจบโมดูลนี้ คุณจะสามารถ:

- อธิบายคุณสมบัติของ Elastic Load Balancing
- แยกความแตกต่างของ load balancer ประเภทต่าง ๆ ของ ELB
- อธิบาย Amazon EC2 Auto Scaling และ launch configurations
- ใช้ EC2 Auto Scaling ใน AWS
- อธิบายคุณสมบัติและตัวเลือกการกำหนดเส้นทาง (routing options) ของ Amazon Route 53
- ตั้งค่า failover routing

หน้า 3 / 76

ภาพรวมของโมดูล

หัวข้อ:

- Elastic Load Balancing (ELB)
- Amazon EC2 Auto Scaling (รวมโจทย์ท้าทายการคาดการณ์)
- Amazon Route 53

การสาธิตแบบบันทึกไว้ (Recorded Demo):

- ตัวเลือกการกำหนดเส้นทางของ Amazon Route 53

แล็บ (Lab):

- Lab 3: ตั้งค่า Amazon EC2 Auto Scaling

โจทย์ท้าทาย (Challenge):

- นำโจทย์ท้าทายการคาดการณ์การขยายขนาดอัตโนมัติ (Leading the Automatic Scaling Prediction Challenge)

แบบฝึกหัด / โปรเจกต์:

- กิจกรรมภาคปฏิบัติที่ 4: ตั้งค่า Failover Routing
- เวลาทำโปรเจกต์: ฐานความรู้สำหรับการแก้ไขปัญหา
- ตรวจสอบความรู้ (Knowledge check)

หน้า 4 / 76

ฐานความรู้สำหรับการแก้ไขปัญหา – ประเด็นของโมดูล 4

- เปิดสำเนาแม่แบบฐานความรู้สำหรับการแก้ไขปัญหาของคุณไว้ในโหมดแก้ไข
- สร้างรายการใหม่ทุกครั้งที่คุณเจอสถานการณ์ที่ต้องแก้ไขปัญห
- หมวดหมู่ที่เน้นในโมดูลนี้:
 - Compute (การประมวลผล)
 - Automation & Optimization (ระบบอัตโนมัติและการปรับให้เหมาะสม)
 - Networking (เครือข่าย)

หน้า 5 / 76

การขยายขนาดตามความต้องการ (Scaling on demand): ภาพรวม

- การซื้อฮาร์ดแวร์เพื่อรองรับความต้องการระยะสั้นทำให้เกิดความสูญเสีย
- ฮาร์ดแวร์ว่างงานในช่วงนอกเวลาเร่งด่วน และไม่เพียงพอในช่วงเวลาเร่งด่วน

ขยายขนาดตามความต้องการด้วย Auto Scaling:

- ขยายออก (scale out) ในช่วงที่ความต้องการพุ่งสูง
- ลดขนาดลง (scale in) ในช่วงนอกเวลาเร่งด่วน
- แทนที่ instances ที่ไม่สมบูรณ์ (unhealthy)
- จ่ายเฉพาะสิ่งที่ใช้

หน้า 6 / 76

ส่วนประกอบที่กล่าวถึง

แผนภาพ: Amazon Route 53 → Elastic Load Balancing (ELB) → Auto Scaling group ที่มี Instance หลายตัว (Instance × 5)

หน้า 7 / 76

โมดูล 4: การประมวลผล (การขยายขนาดและการแปลงชื่อ)

Elastic Load Balancing (ELB)

หน้า 8 / 76

Elastic Load Balancing (ELB)

บริการกระจายโหลดแบบมีผู้ดูแลให้ (managed) ที่กระจายทราฟฟิกของแอปพลิเคชันเข้าไปยัง Amazon EC2 instances, containers และ IP addresses หลายตัว

แผนภาพ: ทราฟฟิกผู้ใช้ (User traffic) → Elastic Load Balancing (ELB) → App × 3

หน้า 9 / 76

ประเภทของ load balancer: ALB

Application Load Balancer (ALB) – HTTP, HTTPS

- จัดการแอปพลิเคชันได้ยืดหยุ่น และรองรับ static IP address
- กระจายโหลดขั้นสูงสำหรับทราฟฟิก HTTP และ HTTPS
- รองรับโปรโตคอลมาตรฐานอุตสาหกรรม (WebSocket และ HTTP/2)
- ทำงานที่ระดับแอปพลิเคชัน (Layer 7)

หน้า 10 / 76

ประเภทของ load balancer: NLB

Network Load Balancer (NLB) – TCP, UDP

- ประสิทธิภาพสูงสุดสำหรับแอปพลิเคชันของคุณ
- รองรับ static IP address
- กระจายโหลดของทราฟฟิก TCP หรือ UDP
- ทำงานที่ระดับการเชื่อมต่อ (Layer 4)

หน้า 11 / 76

ประเภทของ load balancer: CLB

Classic Load Balancer (CLB) – รุ่นก่อนหน้า (PREVIOUS GENERATION) สำหรับ HTTP, HTTPS และ TCP

- สำหรับแอปพลิเคชันที่ใช้เครือข่าย EC2-Classic
- ทำงานทั้งที่ระดับคำขอ (request level) และระดับการเชื่อมต่อ (connection level)

หน้า 12 / 76

ELB load balancer: คุณสมบัติ

ELB load balancers กระจายทราฟฟิกไปยังเป้าหมาย (targets) หลายตัวโดยอัตโนมัติ

- ความพร้อมใช้งานสูง (High availability – HA)
- การตรวจสอบสุขภาพ (Health checks)
- คุณสมบัติด้านความปลอดภัย (Security features)
- การสิ้นสุด TLS (Transport Layer Security termination)
- การกระจายโหลดที่ layer 4 หรือ layer 7
- การเฝ้าติดตามการปฏิบัติงาน (Operational monitoring)

หน้า 13 / 76

Load balancer: Listeners

แผนภาพ: Load balancer → Listener → Rule → Target Group (example.com) ที่มี Target หลายตัว พร้อม Health check

Listeners:

- กระบวนการที่กำหนดพอร์ตและโปรโตคอลที่ load balancer รอรับ (listen)
- load balancer แต่ละตัวต้องมี listener อย่างน้อยหนึ่งตัวเพื่อรับทราฟฟิก
- load balancer หนึ่งตัวมี listener ได้สูงสุด 50 ตัว
- กฎการกำหนดเส้นทาง (routing rules) ถูกกำหนดไว้บน listeners

Load balancer: Target groups

แผนภาพ: Load balancer → Listener → Rule → Target Group (example.com) ที่มี Target หลายตัว พร้อม Health check

Target groups:

- กลุ่มของเป้าหมายที่ลงทะเบียนไว้ ซึ่งรองรับ:
 - EC2 instances
 - ECS container instances
- เป้าหมายตัวเดียวลงทะเบียนกับหลาย target group ได้

ส่วนประกอบของ Application Load Balancer

แผนภาพ: Load Balancer มี Listener หลายตัว แต่ละ listener มี Rule หลายข้อ ส่งไปยัง target groups ต่าง ๆ แต่ละกลุ่มมี Target และ Health check ของตนเอง:

- Target group (example.com)
- Target group (example.com/blog)
- Target group (example.com/mobile)

ตัวอย่าง Application Load Balancer

แผนภาพ: www.example.com → Elastic Load Balancing (ELB) → กระจายตามเส้นทาง (path) ไปยัง Availability Zone A และ B:

- /orders → Orders (ทั้งสอง AZ)
- /images → Images (ทั้งสอง AZ)
- /registration → Reg (ทั้งสอง AZ)

สร้าง Application Load Balancer: AWS CLI

1. ใช้คำสั่ง create-load-balancer เพื่อสร้าง load balancer คุณต้องระบุ subnet สองตัวที่ไม่ได้อยู่ใน Availability Zone เดียวกัน

```
aws elbv2 create-load-balancer \
--name my-load-balancer \
--subnets subnet-12345678 subnet-23456789 \
--security-groups sg-12345678
```

สร้าง target group สำหรับ load balancer

2. ใช้คำสั่ง create-target-group เพื่อสร้าง target group คุณต้องระบุ Amazon VPC ที่ EC2 instances ของคุณทำงานอยู่

```
aws elbv2 create-target-group \
--name my-targets \
--protocol HTTP \
--port 80 \
--vpc-id vpc-12345678
```

ลงทะเบียน EC2 instances เข้า target group

3. ใช้คำสั่ง register-targets เพื่อลงทะเบียน instances ของคุณเข้ากับ target group

```
aws elbv2 register-targets \
--target-group-arn targetgroup-arn \
--targets Id=i-12345678 Id=i-23456789
```

ลงทะเบียน EC2 instances เข้า target group (สร้าง listener)

4. ใช้คำสั่ง create-listener เพื่อสร้าง listener ให้ load balancer โดย listener มีกฎเริ่มต้น (default rule) ที่ส่งต่อคำขอไปยัง target group ของคุณ

```
aws elbv2 create-listener \
--load-balancer-arn loadbalancer-arn \
--protocol HTTP \
--port 80 \
--default-actions Type=forward,TargetGroupArn=targetgroup-arn
```

ตรวจสอบสุขภาพของเป้าหมายที่ลงทะเบียนไว้

5. (ไม่บังคับ) ตรวจสอบสุขภาพของเป้าหมายที่ลงทะเบียนใน target group ด้วยคำสั่ง describe-target-health

```
aws elbv2 describe-target-health --target-group-arn targetgroup-arn
```

ประเด็นสำคัญ (Key Takeaway)

- load balancer มีสามประเภท:
 - Application load balancers
 - Network load balancers
 - Classic load balancers
- listener แต่ละตัวตรวจหาคำขอเชื่อมต่อจากโคลเอนต์ แล้วส่งต่อคำขอไปยัง target group หนึ่งกลุ่มหรือมากกว่าตามกฎที่กำหนด
- แต่ละกฎระบุ target group, เงื่อนไข (condition) และลำดับความสำคัญ (priority)

โมดูล 4: การประมวลผล (การขยายขนาดและการแปลงชื่อ)

Amazon EC2 Auto Scaling

Amazon EC2 Auto Scaling

Amazon EC2 Auto Scaling:

- launch หรือ terminate Amazon EC2 instances โดยอัตโนมัติตาม:
 - การตรวจสอบสถานะสุขภาพ (Health status checks)
 - นโยบายที่ผู้ใช้กำหนดซึ่งขับเคลื่อนด้วย Amazon CloudWatch
 - ตารางเวลา (Schedules)
 - เกณฑ์อื่น ๆ (เช่น ผ่านโปรแกรม)
 - สั่งเองด้วย set-desired-capacity
- ขยายออก (scale out) เพื่อรองรับความต้องการ และลดขนาดลง (scale in) เพื่อลดต้นทุน

EC2 Auto Scaling ขณะทำงาน

Launch Configuration / Launch Template – การตั้งค่าของ instance ที่จะ launch ระบุ:

- AMI
- Instance type
- Security group
- Instance key pair
- พื้นที่จัดเก็บ (Storage)
- IAM roles
- User data

มี launch configuration ที่ใช้งานได้ครั้งละหนึ่งตัวเท่านั้น

EC2 Auto Scaling Group – กลุ่มเซิร์ฟเวอร์ของ EC2 instances

- ขยาย/ลดขนาดอัตโนมัติระหว่าง: Minimum (ต่ำสุด), Desired (ที่ต้องการ – ไม่บังคับ), Maximum (สูงสุด)
- ผสานรวมกับ Elastic Load Balancing (ไม่บังคับ)
- ตรวจสอบสุขภาพเพื่อรักษาขนาดกลุ่ม
- กระจายและถ่วงดุล instances ข้าม Availability Zones

EC2 Auto Scaling Policy – พารามิเตอร์สำหรับการทำงานของ Amazon EC2 Auto Scaling

- ทริกเกอร์ policies อย่างไร? Amazon CloudWatch, instance ล้มเหลว (health check), ตามตารางเวลา, สั่งเอง
- ขยายออกหรือลดลง และมากเท่าใด:
 - ChangeInCapacity (+/-#)
 - ExactCapacity(#)
 - ChangeInPercent (+/-%)
 - ช่วงพัก (Cooldown period) – สำหรับ simple scaling
 - ช่วงอุ่นเครื่อง (Warmup period) – สำหรับ step scaling

EC2 Auto Scaling และสุขภาพของ instance

- เก็บสถานะสุขภาพของ instances
- terminate instances ที่ถูกระบุว่าไม่สมบูรณ์ (unhealthy)
- ใช้การตรวจสอบสถานะของ Amazon EC2 instance เป็นค่าเริ่มต้น
- ตั้งค่าการตรวจเหล่านี้นี้ได้หาก instances อยู่หลัง load balancer:
 - การตรวจ instance ของ load balancer
 - การตรวจ instance ของ Amazon EC2
- ทริกเกอร์การรีไซเคิล instance ได้ด้วยสคริปต์ภายนอก: คำสั่ง aws autoscaling set-instance-health

นโยบายการ terminate ของ EC2 Auto Scaling (termination policy)

Auto Scaling termination policy:

- กำหนดว่า instance ใดจะถูก terminate เมื่อลดขนาดลง (scale in)
- กำหนดลำดับการ terminate ตามปัจจัยต่อไปนี้:
 - Availability Zone ที่มีจำนวน instances มากที่สุด
 - หลายนโยบาย (นโยบายจะถูกรันตามลำดับที่ระบุไว้)

แผนภาพ: Scale Out – เพิ่ม instance ใหม่ (New Instance Added) เข้า Auto Scaling group; Scale In – นำ instance ออก (Instance is Removed) จาก Auto Scaling group

นโยบายการ terminate (Termination policies)

Termination Policy	คำอธิบาย (Description)
OldestInstance	เลือก instance ที่ทำงานนานที่สุด
NewestInstance	เลือก instance ที่ทำงานสั้นที่สุด
OldestLaunchConfiguration	terminate instance ที่มี configuration เก่าที่สุด (ค่าเริ่มต้น – default)
ClosestToNextInstanceHour	terminate instance ที่ใกล้ถึงชั่วโมงคิดเงินถัดไปที่สุด (ค่าเริ่มต้น – default)

การสร้างกลุ่มแบบสถานะคงที่ (steady-state group)

กลุ่มแบบสถานะคงที่:

- ตั้งค่า EC2 Auto Scaling group ให้ค่า min, max และ desired เท่ากัน
 - instance จะถูกสร้างใหม่โดยอัตโนมัติหากไม่สมบูรณ์ (unhealthy) หรือหาก Availability Zone ล้มเหลว
 - ยังอาจมีช่วงหยุดทำงาน (downtime) ระหว่างรีไซเคิล instance
- กรณีการใช้งาน: รักษา NAT server แบบสถานะคงที่ในแต่ละ Availability Zone

แผนภาพ: Auto Scaling group ที่มี Instance เดียว: Min = 1, Max = 1, Desired = 1

การขยายขนาดตามตารางเวลา (Scheduled scaling): Amazon EC2

การขยายขนาดตามตารางเวลาช่วยให้คุณขยายแอปพลิเคชันเพื่อรับมือกับการเปลี่ยนแปลงของโหลดที่คาดเดาได้

(กราฟ: ตัวอย่างกราฟฟิกรายสัปดาห์ของแอปพลิเคชัน – Example weekly traffic to an application – แกนวัน Sun, Mon, Tues, Wed, Thurs, Fri, Sat ชั่วโมงสัปดาห์ แสดงรูปแบบที่เกิดขึ้น)

การขยายขนาดแบบไดนามิก (Dynamic scaling): Amazon EC2

- **Target Tracking Scaling:** เพิ่มหรือลดความจุปัจจุบันของกลุ่มตามค่าเป้าหมายของ metric ที่ระบุ
- **Step Scaling:** เพิ่มหรือลดความจุปัจจุบันของกลุ่มตามชุดการปรับขนาด (scaling adjustments) ซึ่งขึ้นกับขนาดของการละเมิดเกณฑ์ alarm (alarm breach)
- **Simple Scaling:** เพิ่มหรือลดความจุปัจจุบันของกลุ่มตามการปรับขนาดเพียงครั้งเดียว

การขยายขนาดเชิงคาดการณ์ (Predictive scaling): Amazon EC2

Predictive scaling:

- คาดการณ์โหลด (Forecast load)
 - กำหนดตารางความจุขั้นต่ำ (Schedule minimum capacity)
- กรณีการใช้งาน:
- ใช้ร่วมกับ dynamic scaling แบบ target tracking
 - แอปพลิเคชันที่มีโหลดพุ่งขึ้นเป็นรอบ ๆ (periodic spikes)

ประเด็นสำคัญ (Key Takeaway)

- Amazon EC2 Auto Scaling ช่วยรักษาความพร้อมใช้งานของแอปพลิเคชันด้วยการเพิ่มหรือลด EC2 instances โดยอัตโนมัติตามเงื่อนไขที่กำหนด
- EC2 Auto Scaling ประกอบด้วยสามส่วน:
 - Launch configuration / launch template
 - Auto Scaling group
 - Scaling policies
- การขยายขนาดอิงได้กับ:
 - สุขภาพของ instance
 - Amazon CloudWatch alarms
 - ตารางเวลาหรือการใช้งานในอดีต (การคาดการณ์)
- การสร้าง launch configuration ต้องระบุรายละเอียดหลายอย่าง

โจทย์ท้าทาย: นำโจทย์ท้าทายการคาดการณ์การขยายขนาดอัตโนมัติ (Leading the Automatic Scaling prediction challenge)

Sophie ต้องสามารถคาดการณ์ได้

(กราฟ Average CPU Utilization แกน 0%, 20%, 40%, 60%, 80%, 100%: แถบบน 80%–100% คือ Scale-Out Alarm และแถบล่าง 0%–40% คือ Scale-In Alarm)

โจทย์ท้าทาย: เงื่อนไขที่ 1

Alarms ของ step scaling policy:

- Scale-in: ลด 1 instance เมื่อ 40% > average CPU > 20% นานกว่า 2 นาที
- Scale-in: ลด 2 instances เมื่อ 20% > average CPU > 0% นานกว่า 2 นาที
- Scale-out: เพิ่ม 1 instance เมื่อ 60% < average CPU < 80% นานกว่า 2 นาที
- Scale-out: เพิ่ม 2 instances เมื่อ 80% < average CPU < 100% นานกว่า 2 นาที

สำหรับแต่ละเงื่อนไข ให้คาดการณ์จำนวน instances ที่ถูกเพิ่มหรือลด

เงื่อนไขที่ 1 (Condition #1): การใช้ CPU เฉลี่ยอยู่ที่ 63–70% นานกว่า 2 นาที

หมายเหตุ: สมมติว่าเริ่มต้นด้วย 10 instances และตั้งช่วงอุ่นเครื่องของ instance (warmup period) ไว้ 5 นาที

โจทย์ท้าทาย: เงื่อนไขที่ 2

Alarms ของ step scaling policy:

- Scale-in: ลด 1 instance เมื่อ 40% > average CPU > 20% นานกว่า 2 นาที
- Scale-in: ลด 2 instances เมื่อ 20% > average CPU > 0% นานกว่า 2 นาที
- Scale-out: เพิ่ม 1 instance เมื่อ 60% < average CPU < 80% นานกว่า 2 นาที
- Scale-out: เพิ่ม 2 instances เมื่อ 80% < average CPU < 100% นานกว่า 2 นาที

สำหรับแต่ละเงื่อนไข ให้คาดการณ์จำนวน instances ที่ถูกเพิ่มหรือลด

เงื่อนไขที่ 2 (Condition #2): แร่งกตตันต่อ CPU ยังเพิ่มขึ้นต่อเนื่องและคงอยู่ที่ 60–80% ผ่านไป 2 นาทีแล้วนับจากเงื่อนไขที่ 1

หมายเหตุ: สมมติว่าเริ่มต้นด้วย 10 instances และตั้งช่วงอุ่นเครื่องของ instance ไว้ 5 นาที

หน้า 38 / 76

โจทย์ท้าทาย: เงื่อนไขที่ 3

Alarms ของ step scaling policy:

- Scale-in: ลด 1 instance เมื่อ 40% > average CPU > 20% นานกว่า 2 นาที
- Scale-in: ลด 2 instances เมื่อ 20% > average CPU > 0% นานกว่า 2 นาที
- Scale-out: เพิ่ม 1 instance เมื่อ 60% < average CPU < 80% นานกว่า 2 นาที
- Scale-out: เพิ่ม 2 instances เมื่อ 80% < average CPU < 100% นานกว่า 2 นาที

สำหรับแต่ละเงื่อนไข ให้คาดการณ์จำนวน instances ที่ถูกเพิ่มหรือลด

เงื่อนไขที่ 3 (Condition #3): ขณะที่ยังผ่านไปไม่ถึง 5 นาทีนับจากเงื่อนไขที่ 1 ตอนการใช้ CPU อยู่ที่ 85%

หมายเหตุ: สมมติว่าเริ่มต้นด้วย 10 instances และตั้งช่วงอุ่นเครื่องของ instance ไว้ 5 นาที

หน้า 39 / 76

โจทย์ท้าทาย: เงื่อนไขที่ 4

Alarms ของ step scaling policy:

- Scale-in: ลด 1 instance เมื่อ 40% > average CPU > 20% นานกว่า 2 นาที
- Scale-in: ลด 2 instances เมื่อ 20% > average CPU > 0% นานกว่า 2 นาที
- Scale-out: เพิ่ม 1 instance เมื่อ 60% < average CPU < 80% นานกว่า 2 นาที
- Scale-out: เพิ่ม 2 instances เมื่อ 80% < average CPU < 100% นานกว่า 2 นาที

ให้คาดการณ์จำนวน instances ที่ถูกเพิ่มหรือลด

เงื่อนไขที่ 4 (Condition #4): เวลาผ่านไปอีก instance ตัวแรกจากสองตัวที่เพิ่มเข้ามาอุ่นเครื่องเสร็จแล้วและรับโหลดบางส่วน ส่วนตัวที่สองยังอยู่ในสถานะอุ่นเครื่อง แต่การใช้ CPU ลดลงเหลือประมาณ 53% ในช่วง 3 นาทีที่ผ่านมา

หน้า 40 / 76

โจทย์ท้าทาย: เงื่อนไขที่ 5

Alarms ของ step scaling policy:

- Scale-in: ลด 1 instance เมื่อ 40% > average CPU > 20% นานกว่า 2 นาที
- Scale-in: ลด 2 instances เมื่อ 20% > average CPU > 0% นานกว่า 2 นาที
- Scale-out: เพิ่ม 1 instance เมื่อ 60% < average CPU < 80% นานกว่า 2 นาที
- Scale-out: เพิ่ม 2 instances เมื่อ 80% < average CPU < 100% นานกว่า 2 นาที

ให้คาดการณ์จำนวน instances ที่ถูกเพิ่มหรือลด

เงื่อนไขที่ 5 (Condition #5): เมื่อความต้องการใช้งานแอปพลิเคชันลดลง การใช้ CPU ลดลงมากที่ 32%

หน้า 41 / 76

โจทย์ท้าทาย: เงื่อนไขที่ 6

Alarms ของ step scaling policy:

- Scale-in: ลด 1 instance เมื่อ 40% > average CPU > 20% นานกว่า 2 นาที
- Scale-in: ลด 2 instances เมื่อ 20% > average CPU > 0% นานกว่า 2 นาที
- Scale-out: เพิ่ม 1 instance เมื่อ 60% < average CPU < 80% นานกว่า 2 นาที
- Scale-out: เพิ่ม 2 instances เมื่อ 80% < average CPU < 100% นานกว่า 2 นาที

ให้คาดการณ์จำนวน instances ที่ถูกเพิ่มหรือลด

เงื่อนไขที่ 6 (Condition #6): การใช้ CPU ลดลงอีกและตอนนี้อยู่ที่ประมาณ 17%

หน้า 42 / 76

โจทย์ท้าทาย step scaling policy: เฉลย (Answer key)

การคาดการณ์ของคุณตรงกับผลลัพธ์ในกราฟสองกราฟนี้หรือไม่?

Alarms ของ step scaling policy:

- Scale-in: ลด 1 instance เมื่อ 40% > average CPU > 20% นานกว่า 2 นาที
- Scale-in: ลด 2 instances เมื่อ 20% > average CPU > 0% นานกว่า 2 นาที
- Scale-out: เพิ่ม 1 instance เมื่อ 60% < average CPU < 80% นานกว่า 2 นาที
- Scale-out: เพิ่ม 2 instances เมื่อ 80% < average CPU < 100% นานกว่า 2 นาที

เฉลยจากกราฟ Instance Count (Max: 20, Min 5) ตามช่วงเวลาที่เกิดเงื่อนไขในโจทย์:

เงื่อนไข	1	2	3	4	5	6
การเปลี่ยนแปลง	+1	+0	+2	0	-1	-2

(เงื่อนไขที่ 2 ได้ +0 เพราะ instance ที่เพิ่มจากเงื่อนไขที่ 1 ยังอยู่ในช่วงอุ่นเครื่อง; เงื่อนไขที่ 3 เพิ่มรวมเป็น +2 ตามขั้น 80%-100%; เงื่อนไขที่ 4 CPU 53% ไม่เข้าเกณฑ์ alarm ได้จึงไม่เปลี่ยน – ถอดจากกราฟในสไลด์)

(กราฟ Average CPU Utilization แสดงเส้น CPU ขึ้นถึงแถบ Scale-Out Alarm 80% แล้วลดลงถึงแถบ Scale-In Alarm ต่ำกว่า 20% ก่อนกลับขึ้น)

หน้า 43 / 76

หลีกเลี่ยงการขยาย/ลดขนาดกลับไปกลับมา (Avoid thrashing)

ช่วงเวลาที่ alarm ต้องคงอยู่ (Alarm sustain period):

- ตัวอย่าง: CPU utilization > 90% นาน 10 นาที

ช่วงพัก (Cooldown period):

- เมื่อทำการ scale in หรือ out ให้ระงับกิจกรรมการปรับขนาดเพิ่มเติมเป็นระยะเวลาหนึ่ง
- ใช้กับ simple scaling policies
- ตัวอย่าง: ระงับการปรับขนาด 5 นาที

ช่วงอุ่นเครื่องของ instance (Instance warmup period):

- จำนวนวินาทีที่ instance ที่เพิ่ง launch ใช้ในการอุ่นเครื่อง
- ใช้กับ step scaling policies
- ตัวอย่าง: อุ่นเครื่องใช้เวลา 5 นาที

หน้า 44 / 76

Lifecycle hooks ของ EC2 Auto Scaling group

เหตุการณ์ (Event)	ก่อน (Before)	การทำงานของ Auto Scaling	การกระทำของผู้ใช้/โปรแกรม	หลัง (After)
Scale Out	Auto Scaling group ยังไม่มี instance ใหม่	1. launch instance 2. ส่งการแจ้งเตือน	3. ดำเนินการกับ instance (เช่น ติดตั้งซอฟต์แวร์) 4. เพิ่มเข้ากลุ่ม	instance ใหม่อยู่ใน Auto Scaling group
Scale In	instances อยู่ใน Auto Scaling group	1. นำ instance ออกจาก Auto Scaling group 2. ส่งการแจ้งเตือน	3. ดำเนินการกับ instance (เช่น ดึง logs) 4. terminate instance	instance ถูกนำออกจากกลุ่ม

หน้า 45 / 76

โมดูล 4: การประมวลผล (การขยายขนาดและการแปลงชื่อ)

Amazon Route 53

หน้า 46 / 76

Amazon Route 53

Amazon Route 53:

- เป็นเว็บเซิร์ฟเวอร์ Domain Name System (DNS) ที่ขยายขนาดได้
- กระจายทรัพยากรฟิสิกส์ข้าม Regions
- รองรับความพร้อมใช้งานสูงและความหน่วงต่ำ

ความสามารถ:

- จัดทะเบียนหรือโอนย้ายชื่อโดเมน
- แปลงชื่อโดเมนเป็น IP addresses
- กำหนดเส้นทางคำขอตามความหน่วง (latency), health checks, น้ำหนัก (weights) ฯลฯ

หน้า 47 / 76

การผูกชื่อ DNS กับ ELB

- ชื่อ DNS เริ่มต้นจาก ELB:
 - AWS กำหนด hostname ให้ load balancer ของคุณ ซึ่งแปลงเป็นชุดของ IP addresses
 - ตัวอย่าง: web-app.us-west-2.elb.amazonaws.com
- ผูกชื่อ DNS ของคุณเอง:
 - กำหนด hostname ของคุณเองผ่าน alias resource record set
 - สร้าง CNAME record ที่ชี้ไปยัง load balancer ของคุณ
 - ตัวอย่าง: example.com → ALIAS → web-app.us-west-2.elb.amazonaws.com

หน้า 48 / 76

นโยบายการกำหนดเส้นทางของ Amazon Route 53 (routing policies)

Amazon Route 53 รองรับนโยบายการกำหนดเส้นทางเจ็ดแบบต่อไปนี้:

- 1. Simple routing policy (แบบง่าย)
- 2. Weighted routing policy (ตามน้ำหนัก)
- 3. Latency routing policy (ตามความหน่วง)
- 4. Failover routing policy (สลับไปยังระบบสำรอง)
- 5. Geolocation routing policy (ตามตำแหน่งที่มาของ DNS query)
- 6. Geoproximity routing policy (ส่งทราฟฟิกไปยัง AWS Region หรือตามละติจูดและลองจิจูด)
- 7. Multivalue answer routing policy (ตอบหลายค่า)

(แผนภาพ: Amazon Route 53 ส่งทราฟฟิกไปยัง Elastic Load Balancing (ELB) ที่ตำแหน่งต่าง ๆ)

หน้า 49 / 76

การสาธิตแบบบันทึกไว้: ตัวเลือกการกำหนดเส้นทางของ Amazon Route 53

หน้า 50 / 76

การกำหนดเส้นทางตามความหน่วง (Latency-based routing – LBR)

แผนภาพ: ผู้ใช้ (User) ถูกส่งไปยัง Elastic Load Balancing (ELB) ที่ให้ความหน่วงต่ำที่สุด ระหว่าง:

- some-elb-name.us-west-2.elb.amazonaws.com
- some-elb-name.ap-southeast-2.elb.amazonaws.com

หน้า 51 / 76

ตัวอย่าง: การ deploy แบบ Blue/green

แผนภาพ: ผู้ใช้ (User) → Internet → www.example.com → Amazon Route 53

- VPC ระบบเดิม (Existing – blue system): Elastic Load Balancing (ELB) → Instances
- VPC ระบบใหม่ (New – green system): Elastic Load Balancing (ELB) → Instances

Amazon Route 53 weighted routing ค่อย ๆ ย้ายทราฟฟิกจากระบบเดิมไปยังระบบใหม่

หน้า 52 / 76

การทดสอบความสามารถในการขยายขนาด (Testing scalability)

การทดสอบความสามารถในการขยายขนาด:

- พบปัญหาให้เร็วกว่าซ้ำ
- จำลองทราฟฟิกด้วยการทดสอบโหลด (load testing)
- มีเครื่องมือโอเพนซอร์สให้ใช้มากมาย:
 - TheGrinder
 - Apache Jmeter

- Bees with Machine Guns: สคริปต์ทดสอบโหลดอย่างง่ายที่ใช้เฉพาะกับ Amazon EC2

หน้า 53 / 76

ประเด็นสำคัญ (Key Takeaway)

- Amazon Route 53 รองรับนโยบายการกำหนดเส้นทางหลายแบบ
- Amazon Route53 ช่วย:
 - จัดทะเบียน / โอนย้ายชื่อโดเมน
 - แปลงชื่อโดเมนเป็น IP address
- Amazon Route53 รองรับนโยบายการกำหนดเส้นทางหลายแบบ
- Amazon Route53 สามารถส่งทราฟฟิกไปยังทรัพยากรใน AWS regions ต่าง ๆ รวมถึงทรัพยากร on premises
- การกำหนดเส้นทางตามความหน่วง (Latency-based routing – LBR) ช่วยให้ DNS ส่งคำขอของผู้ใช้ไปยัง AWS Region ที่ตอบสนองเร็วที่สุด

หน้า 54 / 76

สรุป

- คุณสมบัติของ Elastic Load Balancing (ELB)
 - ประเภทของ ELB load balancers
 - Amazon EC2 Auto Scaling และ launch configurations
 - คุณสมบัติของ Amazon Route 53
 - การตั้งค่า failover routing
- เพื่อจบโมดูลนี้ให้ทำ:
- ตรวจสอบความรู้ (Knowledge Check)

หน้า 55 / 76

กลยุทธ์การทดสอบ (Test Strategies)

หน้า 56 / 76

สถานการณ์ของโมดูล 4 (Module 4 Scenario)

คลังสินค้าดอกไม้แห่งหนึ่งเพิ่งขยายการจัดส่งดอกไม้และต้นไม้แบบขายส่งไปยังอีกภูมิภาคหนึ่งของประเทศ และเติบโตเกินความคาดหมาย พวกเขามีระบบสั่งซื้อออนไลน์ที่สัญญาว่าจะจัดส่งภายใน 48 ชั่วโมง จึงต้องการการแจ้งคำสั่งซื้อไปยังศูนย์จัดส่ง (fulfillment center) อย่างรวดเร็ว และต้องการวิธีติดตามสต็อกใหม่ประสิทธิภาพมากขึ้น คุณเป็นที่ปรึกษาที่ทำงานกับลูกค้าคลังสินค้าดอกไม้รายนี้ ซึ่งต้องการปรับปรุงโครงสร้างพื้นฐานเพื่อรองรับการเติบโต แต่ต้องปฏิบัติตามข้อกำหนด (compliance requirements)

load balancer ประเภทใดจะให้ประโยชน์มากที่สุดกับโครงสร้างพื้นฐานที่ต้องการ?

- A. Application
- B. Classic
- C. Elastic
- D. ถูกทุกข้อ (All of the above)
- E. ไม่มีข้อใดถูก (None of the above)

หน้า 57 / 76

สถานการณ์ของโมดูล 4 – คำสำคัญ

คลังสินค้าดอกไม้แห่งหนึ่งเพิ่งขยายการจัดส่งดอกไม้และต้นไม้แบบขายส่งไปยังอีกภูมิภาคหนึ่งของประเทศ และเติบโตเกินความคาดหมาย (unexpected growth) พวกเขามี (They have) ระบบสั่งซื้อออนไลน์ที่สัญญาว่าจะจัดส่งภายใน 48 ชั่วโมง จึงต้องการการแจ้งคำสั่งซื้อไปยังศูนย์จัดส่งอย่างรวดเร็ว และต้องการวิธีติดตามสต็อกใหม่ประสิทธิภาพมากขึ้น คุณเป็นที่ปรึกษาที่ทำงานกับลูกค้ารายนี้ ซึ่งต้องการปรับปรุงโครงสร้างพื้นฐานเพื่อรองรับการเติบโต (support the growth) แต่ต้องปฏิบัติตาม (needs to meet) ข้อกำหนดด้าน compliance (compliance requirements)

load balancer ประเภทใด (type of load balancer) จะให้ประโยชน์มากที่สุดกับ (benefit to the desired) โครงสร้างพื้นฐานที่ต้องการ?
(คำที่เป็นตัวหนาคือคำสำคัญที่ไฮไลต์ไว้ในสไลด์ ตัวเลือกถูกปิดไว้)

- A. Application
- B. Classic
- C. Elastic
- D. ถูกทุกข้อ (All of the above)
- E. ไม่มีข้อใดถูก (None of the above)

สถานการณ์ของโมดูล 4 – คำตอบ

คลังสินค้าดอกไม้แห่งหนึ่งเพิ่งขยายการจัดส่งดอกไม้และต้นไม้แบบขายส่งไปยังอีกภูมิภาคหนึ่งของประเทศ และเติบโตเกินความคาดหมาย พวกเขามีระบบส่งชื่อออนไลน์ที่สัญญาว่าจะจัดส่งภายใน 48 ชั่วโมง จึงต้องการการเร่งคำสั่งซื้อไปยังศูนย์จัดส่งอย่างรวดเร็ว และต้องการวิธีติดตามสต็อกให้มีประสิทธิภาพมากขึ้น คุณเป็นที่ปรึกษาที่ทำงานกับลูกค้ารายนี้ ซึ่งต้องการปรับปรุงโครงสร้างพื้นฐานเพื่อรองรับการเติบโต แต่ต้องปฏิบัติตามข้อกำหนดด้าน compliance

- load balancer ประเภทใดจะให้ประโยชน์มากที่สุดกับโครงสร้างพื้นฐานที่ต้องการ?
- A. Application (คำตอบที่ถูกต้อง – ไฮไลต์ในสไลด์)
 - B. Classic
 - C. Elastic
 - D. ถูกทุกข้อ (All of the above)
 - E. ไม่มีข้อใดถูก (None of the above)

Lab 3: ตั้งค่า EC2 Auto Scaling

Lab 3: ตั้งค่า EC2 Auto Scaling

แผนภาพ: Lab VPC: 10.5.0.0/16 เชื่อมต่อ Internet

- Public subnet: 10.5.10.0/24 – มี NAT, Command host และ Elastic Load Balancing (ELB)
- Private subnet: 10.5.50.0/24 – มี Auto Scaling group (สร้างจาก Launch configuration) และ Generic group
- Alarms สำหรับ scale-in หรือ scale-out ควบคุม Auto Scaling group

สถานการณ์โปรเจกต์การปฏิบัติการระบบ (Systems Operations Project Scenario)

Mom & Pop Café & Bakery

AWS กับโลกจริง

Amazon Web Services (AWS) มีบริการหลากหลายหมวดหมู่ เช่น:

- Compute (การประมวลผล)
- Storage (การจัดเก็บข้อมูล)
- Database (ฐานข้อมูล)
- Analytics (การวิเคราะห์ข้อมูล)

AWS มอบโซลูชันบนคลาวด์ให้ทั้งองค์กรขนาดใหญ่และธุรกิจขนาดเล็ก เพื่อขับเคลื่อนการดำเนินงานไปข้างหน้า:

- ได้เร็วขึ้น
- ด้วยต้นทุนที่ลดลง
- พร้อมความสามารถในการขยายขนาดตามความต้องการ

วัตถุประสงค์ของโปรเจกต์

เมื่อทำโปรเจกต์นี้เสร็จ คุณจะสามารถ:

- สัมผัสความท้าทายด้านการสื่อสารที่เกิดขึ้นเมื่อพยายามใช้เทคโนโลยีเป็นทางแก้ปัญหาทางธุรกิจ
- แปลงความต้องการของลูกค้าให้เป็นโซลูชันทางเทคนิคที่เสนอ
- นำเสนอโซลูชันที่เสนอต่อลูกค้า
- ใช้ AWS Best Practices เพื่อให้ได้โซลูชันที่ประหยัด ทนทาน และปลอดภัย

Mom & Pop Café & Bakery: การเตรียมตัวพบลูกค้า (Customer Meeting Preparation)

Mom & Pop Café & Bakery

คำขอให้ขยายเว็บไซต์ไปต่างประเทศ (Request to expand the website internationally)

ความต้องการทางธุรกิจ: การขยายเว็บไซต์

Phillip ตื่นเต้นมาก ร้านสาขาที่สองของเขา กำลังจะเปิดเดือนหน้า ที่รัฐ Virginia ของสหรัฐอเมริกา (US) ใกล้กับลูกพี่ลูกน้องของ Emma ครั้งนี้ Philip ตัดสินใจให้เว็บไซต์พร้อมใช้งานตั้งแต่วันเปิดร้าน เขาขอให้ Sophie ขยายการมีตัวตนของเว็บไซต์ร้านไปทั่วโลก

ก้าวสู่ระดับนานาชาติด้วย Amazon Route 53

Matt ให้ Playbook แก่ Sophie เพื่อใช้ในการแก้ไขปัญหา Raquel ยังแนะนำเว็บไซต์สำหรับพัฒนา Playbook ของพวกเขาเองด้วย (ลิงก์ในสไลด์: Learn more about Playbooks – เรียนรู้เพิ่มเติมเกี่ยวกับ Playbooks)

ฐานความรู้สำหรับการแก้ไขปัญหา

Sophie และ Darsh ตัดสินใจใช้ฐานความรู้สำหรับการแก้ไขปัญหาของ Matt เพื่อเพิ่ม failover routing ให้เว็บไซต์ปัจจุบัน โดยใช้ AWS best practices

สาริตะ: GEOROUTING (การกำหนดเส้นทางตามภูมิศาสตร์)

การ query ตามภูมิศาสตร์ (Geographic queries)

ผู้ใช้ปลายทางจะถูกส่งไปยังตำแหน่งทางภูมิศาสตร์ที่ใกล้ที่สุดได้อย่างไร?

- Resolution #1: (เว้นว่างไว้ให้คิด)
- Resolution #2: (เว้นว่างไว้ให้คิด)
- Resolution #3: (เว้นว่างไว้ให้คิด)

การ query ตามภูมิศาสตร์ (Geographic queries)

ผู้ใช้ปลายทางจะถูกส่งไปยังตำแหน่งทางภูมิศาสตร์ที่ใกล้ที่สุดได้อย่างไร?

- Resolution #1: สร้าง Route 53 Hosted Zone
- Resolution #2: สร้าง record set
- Resolution #3: ใช้ geolocation routing policy

นโยบายการกำหนดเส้นทาง (Routing policy)

นโยบายการกำหนดเส้นทางใดที่ส่ง траฟฟิกตามตำแหน่งทางกายภาพของผู้ใช้ไคลเอนต์?

คำตอบ (Answer): (เว้นว่างไว้ให้คิด)

นโยบายการกำหนดเส้นทาง (Routing policy)

นโยบายการกำหนดเส้นทางใดที่ส่ง траฟฟิกตามตำแหน่งทางกายภาพของผู้ใช้ไคลเอนต์?

คำตอบ (Answer): Geoproximity routing policy

กิจกรรมที่ 4: ตั้งค่า Failover Routing ด้วย Route 53

เวลาทำโปรเจกต์: ฐานความรู้สำหรับการแก้ไขปัญหา

~ 30 นาที

ขอบคุณ (Thank you)

ข้อความลิขสิทธิ์ท้ายสไลด์: ห้ามทำซ้ำหรือเผยแพร่ซ้ำโดยไม่ได้รับอนุญาตเป็นลายลักษณ์อักษรจาก Amazon Web Services, Inc. ห้ามคัดลอก ให้ยืม หรือขายเพื่อการค้า หากมีข้อแก้ไขหรือข้อเสนอแนะเกี่ยวกับคอร์ส โปรดอีเมลมาที่ aws-course-feedback@amazon.com สำหรับคำถามอื่น ๆ ทั้งหมด ติดต่อที่ https://aws.amazon.com/contact-us/aws-training/ เครื่องหมายการค้าทั้งหมดเป็นทรัพย์สินของเจ้าของ